



Institución Educativa
SANTA MARIA
DE LOS ANDES

ESTADÍSTICA COMPUTACIONAL

Bimestre 3 · Introducción al curso



INTRODUCCIÓN AL CURSO

Objetivo principal

Desarrollar el pensamiento e interpretación estadística — y darte las herramientas para lograrlo.

01

Pensar

Cuestionar un dato antes de creerlo.
Reconocer cuándo un promedio
esconde más de lo que muestra.

02

Interpretar

Leer una tabla, un gráfico o un resultado
y explicar honestamente qué dice — y
qué no dice.

03

Aplicar

Usar Python y pandas como el
instrumento profesional para trabajar
con datos reales, a cualquier escala.



¿Por qué Python?

Porque el estándar de la industria no es Excel. Es el lenguaje que usan analistas, ingenieros de datos y científicos de datos en el mundo real.

Escala

Evalúa millones de observaciones sin que el programa se caiga — algo que una hoja de cálculo no puede sostener.

Estándar de industria

Es la herramienta que usan empresas, bancos y centros de investigación para tomar decisiones con datos.

Reproducible

Un análisis en código se puede repetir, auditar y corregir — a diferencia de clics que nadie documentó.

1,000,000+

filas de datos

Excel se vuelve lento o falla. Python +
pandas lo procesan en segundos.



INTRODUCCIÓN AL CURSO

¿Qué es pandas?

La librería ya construida para hacer análisis de datos en Python.

departamento	poblacion	año
Lima	9485405	2017
Cusco	1205527	2017
Madre de Dios	141070	2017
...	...	...

```
import pandas as pd
```

Así se importa — una línea, y tienes acceso a todo.

```
.head() / .describe()
```

Comandos para “ver” y “resumir” un dataset entero al instante.

DataFrame

La tabla — filas de observaciones, columnas de variables — es la unidad base de todo el curso.



INTRODUCCIÓN AL CURSO

El mapa de las 8 semanas

Hoy estamos aquí



SEMANA 1

La Importancia de la Interpretación



APERTURA

Dos titulares. Los dos hablan de lo mismo.

TITULAR A

**“El departamento peruano promedio tiene
1.18 millones de habitantes”**

TITULAR B

**“El departamento peruano típico tiene 0.85
millones de habitantes”**


Ambos números son correctos. Ambos salen exactamente de los mismos datos.

¿Cuál le creerías?



APERTURA

Mismos datos, dos preguntas distintas



Población por departamento del Perú (Censo INEI, 2017) — 25 unidades: 24 departamentos + Callao

Lima: 9.49 millones de hab.

Más de 10 veces la mediana — y jala la media hacia arriba.

La media (1.18 M) responde: “¿cuánta gente habría por departamento si la población total se repartiera en partes iguales?”

La mediana (0.85 M) responde: “¿cuántos habitantes tiene el departamento típico, el de en medio?”

Fuente: INEI — Censos Nacionales 2017: XII de Población y VII de Vivienda

SEMANA 1

La Estadística



1.1 · TEORÍA DESBLOQUEADA

¿Qué es la Estadística?

La ciencia de recolectar, organizar, analizar e interpretar datos para tomar decisiones informadas y entender el mundo.

No es un ejercicio académico abstracto — separa “la opinión de alguien” de “lo que realmente muestra la evidencia”.

Periodismo

Verificar si un titular sobre “la ciudad más peligrosa” dice lo que parece decir.

Medicina

Decidir si un tratamiento funciona mejor que otro.

Deporte

Fichar según el rendimiento real de un jugador, no su fama.

Gobierno

Invertir recursos públicos según la necesidad real.

Negocios

Decidir qué producto funciona, para quién y por qué.



1.2 · TEORÍA DESBLOQUEADA

Las tres ramas de la estadística

Descriptiva

¿Qué pasó?

Semanas 1–5 — el núcleo de este módulo

Predictiva

¿Qué es probable que pase?

Semana 6 (regresión lineal)

Prescriptiva

¿Qué deberíamos hacer al respecto?

Este curso no construye una herramienta prescriptiva



1.3 · TEORÍA DESBLOQUEADA

Media, Mediana y Moda

Media

La suma de todos los valores dividida entre la cantidad de valores. Sensible a valores extremos — uno solo puede “jalar” la media.

Mediana

El valor central de los datos una vez ordenados de menor a mayor. Resistente a valores extremos.

Moda


El valor que se repite con más frecuencia. Es la más útil cuando los datos son categóricos.

Cuando media y mediana difieren mucho, eso es información, no ruido: indica que la distribución está sesgada. No se trata de que “la mediana sea más correcta” — se trata de que cuál usar depende de qué se quiere describir con honestidad.



1.3 · TEORÍA DESBLOQUEADA

¿Por qué se separan? El sesgo



Cuando hay valores extremos (“colas largas”) en una sola dirección:

La media se corre hacia la cola — los extremos la “jalan”.

La mediana se queda cerca de donde está “la mayoría” de los casos.

Así es exactamente como Lima empuja la población promedio por departamento muy por encima del departamento “típico”.

SEMANA 1

Exploración de Datos en Python



SECCIÓN A · ATERRIZAJE

.head() · .info()

Un dataset es una tabla de observaciones (filas) y variables (columnas) — no es “la verdad absoluta”, es un registro de algo, que puede estar incompleto o tener errores.

.head()

Muestra las primeras filas. Es la primera mirada — ¿qué tipo de datos tengo entre manos?

.info()

Resume tipos de dato y valores no nulos por columna. Revela huecos antes de que arruinen un análisis.


RECONOCIMIENTO, NO SINTAXIS

Valores faltantes, tipos de datos raros o un número de filas inesperado — solo se detectan si se mira primero.



SECCIÓN B · RECONOCIMIENTO

.describe() · media, mediana, desviación estándar



Al correr `.describe()` sobre el dataset de población por departamento (INEI):

<code>mean</code>	1,175,275
<code>50% (mediana)</code>	850,765
<code>std</code>	1,799,928
<code>max (Lima)</code>	9,485,405

La población departamental está sesgada — Lima, ella sola, jala la media muy por encima de la mediana. Ese es el ejemplo real que paga la promesa de la apertura.