



SEMANA 2

Filtra el ruido. Compara grupos.



SECCIÓN C · FILTRA EL RUIDO

Filtrar es preguntar

Filtrar es hacerle una pregunta específica a los datos.

“Muéstrame solo los atletas mayores de 30 años.”

Cada línea de código de filtrado es, en el fondo, una pregunta que decidiste hacer — y otras diez que decidiste no hacer.



SECCIÓN C · FILTRA EL RUIDO

La sintaxis del filtrado

Una condición

```
df[df['edad'] > 30]
```

Dentro de los corchetes va una prueba verdadero/falso, fila por fila.

Combinar condiciones

```
df[(df['edad'] > 30) & (df['pais'] == 'PER')]
```

Con & (“y”) o | (“o”) — cada condición va entre paréntesis propios.



SECCIÓN C · FILTRA EL RUIDO

Errores comunes que hay que evitar

Usar and / or en vez de & / |

✗ ~~df[df['edad'] > 30 and df['pais'] == 'PER']~~

✓ df[(df['edad'] > 30) & (df['pais'] == 'PER')]

Olvidar los paréntesis de cada condición

✗ ~~df[df['edad'] > 30 & df['pais'] == 'PER']~~

✓ df[(df['edad'] > 30) & (df['pais'] == 'PER')]

Confundir = (asignar) con == (comparar)

✗ ~~df[df['edad'] = 30]~~

✓ df[df['edad'] == 30]

Encadenar corchetes para asignar un valor

✗ ~~df[df['edad'] > 30]['activo'] = True~~

✓ df.loc[df['edad'] > 30, 'activo'] = True



NOTA DE PRECISIÓN ESTADÍSTICA

Un valor atípico no es automáticamente un error.

Es una observación inusual. Confundirlo con un “dato malo” es el malentendido más común en estudiantes nuevos a estadística.



SECCIÓN C · FILTRA EL RUIDO

Atípicos genuinos, no fabricados

Valores extremos reales de la historia olímpica — así el concepto se sostiene sobre datos verdaderos.

EDAD

72 años

Oscar Swahn

Tiro, Suecia · 1920

El olímpico más viejo de la historia. El más joven, Dimitrios Loundras, compitió con 10 años (1896).

ESTATURA

2.26 m

Yao Ming

Baloncesto, China · 2008

El olímpico más alto registrado. Los más bajos, Rosario Briones y Lyton Mphande, midieron 1.27 m.

PESO

218 kg

Ricardo Blas Jr.


Judo, Guam · 2012

El competidor más pesado en unos Juegos Olímpicos, en la categoría +100 kg de judo.



SECCIÓN C · FILTRA EL RUIDO

Así se ve un atípico real





SECCIÓN D

Compara grupos

.groupby() · donde vive el verdadero hallazgo



SECCIÓN D · COMPARA GRUPOS

.groupby()

Comparar promedios por subgrupo es donde vive el verdadero hallazgo.

EL PUNTO CENTRAL

El promedio general puede esconder lo que realmente pasa dentro de cada grupo.

Un solo número puede ser honesto y, al mismo tiempo, ocultar la historia completa.



SECCIÓN D · COMPARA GRUPOS

La sintaxis de `.groupby()`

Un promedio por grupo

```
df.groupby('deporte')['estatura'].mean()
```

Agrupar las filas por valor de la columna y sacar el promedio de otra.

Agrupar por más de una columna


```
df.groupby(['deporte', 'sexo'])['estatura'].mean()
```

Una lista de columnas crea subgrupos dentro de subgrupos.



SECCIÓN D · COMPARA GRUPOS

El deporte importa



Estatura promedio de atletas olímpicos por deporte (Río 2016)

2.00 m vs. 1.68 m

Baloncesto y gimnasia: 32 centímetros de diferencia entre promedios de deporte.

El promedio general (1.82 m) no está “mal” — solo describe a nadie en particular.



NOTA DE PRECISIÓN ESTADÍSTICA

**“Comparar grupos muestra
qué es diferente,
no por qué es diferente.”**

La barrera mínima contra una lectura causal prematura. El “por qué” es trabajo protegido de la Semana 5 — hoy no lo gastamos.



Dos herramientas nuevas.

Filtrar es preguntar con precisión. Comparar grupos es donde el promedio general empieza a contar la verdad completa.

- Un valor atípico no es un error — investigalo antes de borrarlo
- Un promedio general puede ocultar lo que pasa en cada grupo
- “Qué es diferente” todavía no es “por qué es diferente”